UNIVERSIDAD DE CELAYA · INGENIERÍA EN CIENCIA DE DATOS

# Informe Ejecutivo — Análisis del Problema y Viabilidad de Datos del Proyecto CIMAT

Datos + Derecho + Tecnología para Evaluar Vulnerabilidad de Compliance (ISO 37301) en MIPYMES y Modelar Redes Societarias de Operaciones Simuladas (Art. 69-B del CFF)

| | |
|---|---|
| **Materia:** | Programación Avanzada (Tercer Semestre · Ago–Dic 2026) |
| **Dirigido a:** | Dr. Manuel Ledesma López (Investigador Principal del Proyecto) y Equipo de Derecho |
| **Repositorio Git:** | cimat-compliance-pymes (Entrega grupal: docs/informe-ejecutivo.md) |
| **Fecha:** | 19 de octubre de 2026 |

## Integrantes del Grupo, Subequipos y Autoría por Sección

| Subequipo | Integrante (Nombre Completo) | Alias Git | Sección Redactada y Defendida en este Informe |
|---|---|---|---|
| **Requerimientos** | Ana Paula Navarro López | Pau N.L. | **Sección 1.** Resumen ejecutivo y **Sección 2.** El problema en el mundo real |
| **Datos** | Santiago Alvarado Delgadillo | Santiago A.D. | **Sección 3.** ¿Qué es compliance y qué mide el dataset? (ISO 37301 y contrato de fila) |
| **Requerimientos** | Mariana Martínez Ruelas | Mariana M.R. | **Sección 4.** Alcance honesto del proyecto y **Sección 8.** Preguntas para Derecho |
| **Datos** | Gerardo Jamaica Grande | Gerardo J.M. | **Sección 5 (Parte A).** Diagnóstico estructural del dataset, escalas y Excel vs. CSV |
| **Calidad** | Benny Joan Salvador Mosqueda Saldaña | Benny M.S. | **Sección 5 (Parte B).** Los 10 problemas y riesgos de calidad de datos identificados |
| **Arquitectura + Inv.** | Luis Alonzo Hernández Silva | Alonzo H.S. | **Sección 6.** Rol de cada área, flujo del pipeline, 4 frentes y acceso al clúster CIMAT |
| **Calidad** | Romina Centeno Gámez | Romina C.G. | **Sección 7.** Restricciones y reglas no negociables (anonimización, cómputo y calendario) |
| **Arquitectura + Inv.** | Santiago Aguilar Hernández | Santiago A.H. | **Sección 9.** Recomendación estratégica, sustento de literatura y siguientes pasos |

## 1. Resumen Ejecutivo

**El problema:** En México, numerosas micro, pequeñas y medianas empresas (MIPYMES) operan con alta informalidad interna, lo que las vuelve vulnerables a involucrarse —incluso sin advertirlo— con empresas fachada que emiten facturas por **operaciones simuladas** (reguladas en el **Artículo 69-B del Código Fiscal de la Federación, CFF**). Estas empresas factureras no actúan de forma aislada, sino agrupadas en **redes societarias** que reutilizan socios, representantes legales y domicilios fiscales (*Explicación sin tecnicismos*, 29-sep-2026, §1–2).

**Hallazgo principal sobre los datos:** Al auditar el dataset piloto entregado por Derecho (**Dataset.csv**, con **18 registros** de **3 PYMES** evaluadas en las **6 categorías de ISO 37301**), confirmamos dos hechos críticos: (1) los tres equipos jurídicos usaron escalas distintas (dos de madurez y una de riesgo probabilidad × impacto), por lo que **el 33.3% del dataset (6 de 18 filas) tiene confianza de homologación baja** y persisten pistas en notas de texto que permitirían re-identificar a una PYME (municipio de Villagrán); y (2) el archivo web del SAT incluido como referencia apunta por error al **Art. 69-B Bis** (*transmisión indebida de pérdidas fiscales*, con solo 2 oficios en PDF), cuando el proyecto requiere el padrón del **Art. 69-B** (*operaciones simuladas / EFOS*).

**Recomendación del grupo:** Ejecutar de inmediato y en paralelo los dos frentes libres de bloqueos externos: **Frente 1**, automatizar la limpieza, sanitización de cuasi-identificadores y homologación documentada del dataset de PYMES; y **Frente 2**, construir el dataset público estructurado del **Art. 69-B** bajo un diseño *Positive-Unlabeled (PU)*. Con esa base, en noviembre modelaremos los grafos societarios (**Frente 3**) y en diciembre entregaremos los paquetes reproducibles sin salida a pantalla para que el Dr. Ledesma ejecute la corrida final en el clúster del CIMAT antes del **31 de diciembre de 2026** (**Frente 4**) (*Guion 28-sep-2026*, Anexo).

## 2. El Problema en el Mundo Real

En la práctica fiscal mexicana existen entidades creadas únicamente en papel: cuentan con acta constitutiva y registro ante el SAT, pero carecen de personal, maquinaria, inventarios o instalaciones reales. Su actividad consiste en vender comprobantes fiscales de bienes o servicios inexistentes (**Empresas que Facturan Operaciones Simuladas, EFOS**). Otras empresas con operación real compran esas facturas para inflar gastos deducibles y pagar menos impuestos (**Empresas que Deducen Operaciones Simuladas, EDOS**), o bien contratan a un proveedor fachada por no verificar su existencia material (*Explicación sin tecnicismos*, 29-sep-2026, §1).

Cuando el SAT detecta que un contribuyente factura sin capacidad material, lo publica en el **Listado del Artículo 69-B del CFF**, la única base oficial en México con casos verificados por la autoridad, dividida en estados procesales: **presuntos** (notificados para aclarar), **definitivos** (no lograron acreditar la materialidad), **desvirtuados** (acreditaron pruebas) y **con sentencia favorable**. Estas factureras rara vez operan solas: dado que constituir sociedades implica costos notariales y bancarios, quienes operan estos esquemas reutilizan **los mismos representantes legales, accionistas, comisarios, notarios y domicilios fiscales**, además de facturarse en círculo (*Literatura relacionada*, 28-sep-2026, §1–2: Zumaya et al., 2021; Luna-Pla y Nicolás-Carlock, 2020). Esos elementos compartidos forman **redes societarias** que pueden descubrirse mediante **grafos** (mapas matemáticos donde cada punto es una empresa o persona y cada línea es un vínculo compartido).

## 3. ¿Qué es Compliance y Qué Mide el Dataset?

El término **compliance** (cumplimiento normativo) describe qué tan preparada está una empresa desde adentro para prevenir que sea utilizada para cometer fraudes o infracciones legales (*Explicación sin tecnicismos*, 29-sep-2026, §2). Los alumnos de Derecho evaluaron a las PYMES contra el estándar internacional **ISO 37301**, organizado en **6 categorías fijas**:

| Categoría ISO 37301 en Dataset.csv | Cláusula | ¿Qué mide dentro de la organización? |
|---|---|---|
| **1. Gobierno corporativo y contrapesos** | 5.3 | Órganos colegiados de decisión, actas formales y límites al poder concentrado en un solo socio. |
| **2. Función de cumplimiento** | 5.3 | Persona o comité responsable de vigilar normas fiscales, sanitarias, laborales y regulatorias. |
| **3. Políticas y procedimientos documentados** | 7.5 | Código de ética, política anticorrupción y reglamentos internos actualizados y registrados. |
| **4. Canal de denuncias e investigación interna** | 8.3 y 8.4 | Buzón confidencial sin represalias y protocolo documentado para investigar irregularidades. |
| **5. Gestión de riesgos y control interno** | 8.1 y 8.2 | Matrices de riesgo, auditoría de contratos con proveedores y cláusulas de cumplimiento. |
| **6. Gobernanza de datos e inteligencia artificial** | 7.5 (IA) | Reglas para no filtrar datos personales de clientes ni secretos comerciales en herramientas de IA. |

**¿Qué representa una fila del dataset piloto?** Cada fila de *Dataset.csv* **no representa a una empresa completa ni a un contrato**, sino la **evaluación de una de las 6 categorías de ISO 37301 para una PYME específica** (par PYME × Categoría). Por ello, cada PYME diagnosticada ocupa exactamente 6 filas consecutivas.

## 4. Alcance Honesto del Proyecto

El proyecto separa estrictamente dos piezas de datos (*Explicación sin tecnicismos*, 29-sep-2026, §3 y §5): la **Pieza A** (diagnósticos de compliance de PYMES en *Dataset.csv*, que miden vulnerabilidad interna) y la **Pieza B** (el listado público del Art. 69-B del SAT, que contiene empresas confirmadas como factureras de operaciones simuladas).

**¿Por qué hoy NO es válido concluir que una PYME con baja calificación comete fraude fiscal?** (1) Porque carecer de un comité o canal de denuncias (nivel 1, *Inexistente*) refleja informalidad administrativa típica de una microempresa, no emisión ni compra de

facturas falsas; (2) porque no existe ningún vínculo probado entre las PYMES de la Pieza A y el listado 69-B; y (3) porque, como demuestra la literatura (**Medina-Hernández et al., 2025**; **Mittal et al., 2018**), el listado 69-B no es una etiqueta binaria simple, sino un esquema **Positive-Unlabeled (PU)** con tres estados procesales (*presuntos, definitivos, desvirtuados*) donde las empresas no listadas son "no identificadas aún", no "inocentes confirmadas". Además, **Barwahwala et al. (2024)** advierten que incluso modelos con alta exactitud estadística no garantizan impacto fiscal directo.

**¿Qué SÍ se entregará en 2026?** (1) Un **pipeline reproducible y documentado** (limpieza → estructuración → grafos → visualización); (2) el **primer dataset estructurado del listado 69-B**; (3) un **prototipo exploratorio de grafos societarios**; y (4) **evidencia metodológica** para sustentar artículos académicos y diseñar en 2027 una validación formal.

## 5. Diagnóstico de los Datos Disponibles

**Evidencia cuantitativa y diferencias entre Excel y CSV:** El archivo *Dataset.csv* contiene **18 registros** y **19 columnas**, producto de evaluar **3 PYMES** por **3 equipos de Derecho** (3 × 6 = 18). Mientras la versión original en Excel (*2026-09-18_dataset-consolidado-pymes-h1_v1.xlsx*, citada en el *Guion del 28-sep*) estaba en formato propietario y sin homologar, la versión *Dataset.csv* (29-sep) migró a texto separado por comas y añadió **6 columnas de homologación en borrador** (*tipo_escala_equipo, valor_escala_original, nivel_homologado_borrador, etiqueta_homologada_borrador, confianza_homologacion, observaciones_calidad_dato*).

| Equipo / ID PYME | Perfil en Dataset | Escala Original Usada | Homologación Borrador | Confianza |
|---|---|---|---|---|
| **equiporisan**<br>COS-BJ-01 | Cosméticos · S. de R.L. de C.V. (14 emp., 6 años, Gto.) | Escala de madurez 1–2 (1=Inexistente, 2=Ad hoc) | Nivel 1 (4 filas)<br>Nivel 2 (2 filas) | **Alta**<br>(6 filas / 33.3%) |
| **equipoN**<br>PYME-001 | Lácteos · S.A. de C.V. (Micro, 5–10 años, región s/d) | Escala de madurez 1–4 con semáforo | Nivel 1 (6 filas)<br>*(reclasificado a rojo)* | **Alta**<br>(6 filas / 33.3%) |
| **equipoJP**<br>CONS-SERV-01 | Construcción · Persona física (Micro, >10 años, Bajío) | Matriz de riesgo Probabilidad × Impacto | Nivel 1 (5 filas)<br>Nivel 2 (1 fila) | **Baja**<br>(6 filas / 33.3%) |

**¿Por qué las tres escalas no son directamente comparables?** Porque *equiporisan* (1–2, truncada arriba) y *equipoN* (1–4) miden **madurez de controles**, mientras que *equipoJP* evaluó **exposición al riesgo (probabilidad × impacto)**. Medir qué tan probable es un daño no equivale a medir qué tan formalizado está un control; por ello, un tercio del dataset (6 filas) tiene **confianza baja**. Además, identificamos **10 problemas de calidad de datos**:

| # | Problema / Riesgo de Calidad | Evidencia Concreta en Dataset.csv y Contexto | Impacto en el Proyecto |
|---|---|---|---|
| **1** | **Constructo distinto (Riesgo vs. Madurez)** | Filas 14–19 (*equipoJP*): usa matriz Probabilidad × Impacto en vez de madurez. | 33.3% del dataset tiene confianza de homologación baja. |
| **2** | **Fuga de cuasi-identificadores en notas** | Filas 14–19 (*observaciones_calidad_dato*): revela **Villagrán**, **11 años** y **4 personas**. | Riesgo crítico de re-identificar a CONS-SERV-01 al cruzar con giro. |
| **3** | **Valores exactos sin agrupar en banda** | Filas 2–7 (*COS-BJ-01*): dice *"6 años"* y *"14 empleados"* en vez de rangos. | Rompe anonimización en bandas y rebasa umbral de microempresa (<=10). |
| **4** | **Texto global copiado en 6 categorías** | Filas 8–13 (*equipoN*): idéntico hallazgo, evidencia y recomendación en las 6 filas. | Pérdida total de detalle por categoría ISO 37301 en PYME-001. |
| **5** | **Contradicción Nivel 1 vs. Semáforo Verde** | Filas 8–13 (*equipoN*): reportó promedio 1/4 (Inexistente) pero con semáforo verde. | Requirió reclasificación manual a semáforo rojo al consolidar. |
| **6** | **Incoherencia con Persona Física** | Fila 14 (*CONS-SERV-01*): pide *consejo de administración de 3 miembros* a Persona física. | Error jurídico: una persona física no es sociedad mercantil. |
| **7** | **Omisiones de entrevista imputadas** | Filas 3, 4 y 6 (*equiporisan*): sin hallazgo en entrevista, rellenadas como nivel 1 y 2. | Confunde ausencia de control con falta de pregunta en entrevista. |
| **8** | **Cláusulas y nulos no normalizados** | Mezcla *"5.3 Roles..."*, *"5.3"* y *"No reportada en el archivo fuente"*. | Dificulta agregación automática sin diccionario de limpieza. |
| **9** | **Marca UTF-8 BOM e imagen en Word** | El CSV inicia con el carácter invisible *\ufeff*; matriz de *equipoJP* vino en imagen. | Renombra la columna a *\ufeffequipo* y añade riesgo de transcripción. |
| **10** | **Fuente SAT apunta a Art. 69-B Bis** | *SAT listado del Art. 69-B del CFF.htm* descarga el listado del **Art. 69-B Bis** (pérdidas fiscales). | El Frente 2 requiere el padrón de **EFOS (Art. 69-B)**, no el 69-B Bis. |

## 6. Rol de Cada Área y Flujo de Trabajo

**Articulación de las tres áreas:** (1) **Derecho** define el problema jurídico, realiza la curaduría y anonimización de datos de las PYMES, parametriza las variables ISO 37301 y valida criterios legales; (2) **Ciencia de Datos** —organizada en nuestros cuatro subequipos de *Requerimientos, Datos, Calidad y Arquitectura/Investigación* (*Equipos.md*)— diseña y construye los programas de validación, estructuración y grafos; y (3) **CIMAT** provee la plataforma de supercómputo de alto rendimiento (*Clúster El-Insurgente* y *Laboratorio de Supercómputo del Bajío*) (*Lámina de arranque CIMAT.png*, §4).

**El pipeline propuesto y los cuatro frentes:** Un *pipeline* es una cadena automatizada de pasos reproducibles: **Limpieza (Frente 1)**: homologar programáticamente el dataset de PYMES y convertir de Excel a CSV limpio; **Estructuración (Frente 2)**: transformar el listado público del Art. 69-B del SAT y fuentes registrales públicas en una tabla limpia (empresa, domicilio, representante legal, fecha, estatus presunto/definitivo/desvirtuado); **Grafos (Frente 3)**: construir y medir las redes de empresas conectadas con las herramientas

*NetworkX* y *PyVis*; y **Preparación para el clúster (Frente 4)**: empaquetar scripts y lista de dependencias (*requirements.txt*). **Restricción de acceso al clúster:** Por disposición de la convocatoria firmada con el CIMAT, la cuenta de acceso (*proy_ai26_manuel.ledesma*) es exclusiva del solicitante; por tanto, Ciencia de Datos desarrolla y prueba localmente, y el **Dr. Manuel Ledesma ejecuta las corridas finales en el clúster** (*Explicación sin tecnicismos*, 29-sep-2026, §6).

## 7. Restricciones y Reglas No Negociables

- **1. Protección de datos personales y anonimización estricta:** Ningún nombre, razón social, RFC ni domicilio exacto de las PYMES puede aparecer en el código, en GitHub ni en el clúster. También deben limpiarse las pistas indirectas (como el municipio de Villagrán en *observaciones_calidad_dato*) por obligación legal y ética hacia las empresas participantes.
- **2. Uso real y buenas prácticas del supercómputo con el volumen actual:** Con 18 registros actuales (y algunos miles en el listado 69-B), **el proyecto hoy no requiere tarjetas gráficas (GPU) ni cómputo masivo**; el clúster se utiliza para estandarizar la arquitectura hacia 2027. Conforme al *Manual de Acceso a Recursos del CIMAT* (2025, pp. 13, 18, 22 y 30–32) y su *Reglamento* (tope de 150 núcleos / 500 GB): (a) jamás ejecutar procesos en el servidor de entrada (*Front-End*); (b) **prohibido imprimir resultados en pantalla** (*stdout* o redirección >), escribiendo todo directamente a archivos en disco para no degradar las cachés distribuidas; y (c) agrupar ejecuciones secuenciales mediante el gestor de tareas **Slurm** (particiones CPU como *C1Mitad1* o *C2*) o *MPI_Scheduler* para no bloquear nodos completos con un solo hilo.
- **3. Calendario inamovible:** El proyecto corre de agosto a diciembre de 2026, con entregable obligatorio ante el CIMAT el **31 de diciembre de 2026** (más el reporte final de 2 a 4 páginas dentro de las 4 semanas posteriores).

## 8. Preguntas para el Área de Derecho (Antes de Programar)

- **1. Equivalencia Riesgo vs. Madurez:** ¿Validan jurídicamente la regla inversa *Riesgo Alto = Madurez 1 (Inexistente)* y *Riesgo Medio-Alto = Madurez 2 (Ad hoc)* usada en *CONS-SERV-01*, o debe tratarse en una escala separada?
- **2. Escala única para entregas restantes:** ¿Los equipos de Derecho que faltan por entregar usarán ya una sola escala obligatoria (p. ej. madurez 1–4 en tabla editable, prohibiendo imágenes pegadas en Word)?
- **3. Sanitización de cuasi-identificadores:** ¿Autorizan que el script de limpieza enmascare el municipio (*Villagrán*) y datos exactos (*11 años, 4 personas*) en *observaciones_calidad_dato*, y agrupe en bandas a *COS-BJ-01* (*6 años, 14 empleados*)?
- **4. Categorías no abordadas en entrevista:** En *COS-BJ-01* tres dimensiones sin hallazgo en entrevista se rellenaron como niveles 1 y 2. ¿Deben mantenerse así o marcarse como *No evaluadas (NA)* para no sesgar el promedio?
- **5. Controles para Personas Físicas:** Dado que una *Persona física con actividad empresarial* (*CONS-SERV-01*) no tiene consejo de administración, ¿qué control equivalente de la cláusula 5.3 de ISO 37301 debemos validar en estos casos?
- **6. Confirmación Art. 69-B vs. 69-B Bis:** Detectamos que el archivo HTML en *Contexto* apunta al **Art. 69-B Bis** (pérdidas fiscales). ¿Confirmamos usar el padrón de Datos Abiertos del **Art. 69-B (EFOS)** y cómo ponderar sus estados (*definitivo, presunto, desvirtuado, sentencia favorable*)?
- **7. Fuentes públicas para conexiones del grafo:** Como el CSV del 69-B solo publica RFC y razón social, ¿qué fuentes públicas (RPPC/SIGER, Boletín Registral, contrataciones públicas) proveerá o validará Derecho para obtener socios, representantes legales y domicilios compartidos?
- **8. Naturaleza de fuentes y confidencialidad:** ¿Se confirmó que las PYMES de la Pieza A son casos reales y requieren los alumnos de Ciencia de Datos firmar un convenio de confidencialidad equivalente al de Derecho?

## 9. Recomendación y Siguientes Pasos

Proponemos un plan de desarrollo incremental en 4 bloques que permite avanzar desde hoy sin depender del acceso al clúster:

| Periodo | Frente y Subequipos | Acción y Entregable Verificable |
|---|---|---|
| **Semanas 1–2** (Octubre) | **Frente 1** Datos + Calidad + Req. | Consolidar el validador automático (*src/validation.py* y *src/homologacion.py*), eliminar marca BOM, enmascarar cuasi-identificadores y entregar el análisis exploratorio (EDA) de las PYMES. |
| **Semanas 3–4** (Noviembre) | **Frente 2** Datos + Requerimientos | Descargar y estructurar el listado público del **Art. 69-B del SAT** (EFOS) con etiquetado *Positive-Unlabeled (PU)* y cruzar atributos societarios públicos (*src/sat_69b_etl.py*). |
| **Semanas 5–6** (Fin Nov.) | **Frente 3** Arquitectura + Calidad | Construir y visualizar los grafos societarios preliminares (*NetworkX / PyVis*) identificando componentes conexas, grado e intermediación (*src/graph_builder.py*). |
| **Semanas 7–8** (Dic. → 31-dic) | **Frente 4** Arquitectura + Grupo | Empaquetar el repositorio con escritura directa a disco (cero *stdout*) y scripts *sbatch* de Slurm para que el Dr. Ledesma ejecute la corrida oficial en el CIMAT antes del 31 de diciembre. |

## Anexo A — Declaración de Uso de Herramientas de Inteligencia Artificial

En cumplimiento de las reglas de transparencia de la actividad (*Actividad Informe ejecutivo — Análisis del problema del Proyecto CIMAT*, Reglas importantes): se empleó el asistente *Antigravity (Gemini)* como herramienta de apoyo para la verificación cruzada de los documentos de la carpeta *Contexto*, la inspección programática de las 18 filas y 19 columnas de *Dataset.csv*, la estructuración editorial de tablas y el empaquetado de scripts base en Python. El análisis crítico, la identificación de los 10 problemas de calidad (incluyendo el desfase entre el Art. 69-B y el Art. 69-B Bis y la fuga de cuasi-identificadores en notas de observaciones), las preguntas dirigidas al área de Derecho y la defensa oral corresponden al trabajo y validación de los 8 integrantes del grupo.

## Anexo B — Referencias Documentales y Bibliográficas del Proyecto

1. **Ledesma López, M. (29 de septiembre de 2026).** *El Proyecto CIMAT, explicado sin tecnicismos legales. Documento de apoyo para la reunión con el equipo de Ciencia de Datos* (Explicación.docx).
2. **Ledesma López, M. (28 de septiembre de 2026).** *Guion — Primera Sesión de Trabajo Conjunta, Ciencia de Datos × Proyecto CIMAT* (2026-09-28_guion_primera_sesion_trabajo_ciencia_datos_v1.md.docx).
3. **Ledesma López, M. (28 de septiembre de 2026).** *Referencias de Literatura Relacionada — Modelado de Grafos y Analítica de Datos Masivos para la Detección Preventiva de Redes de Evasión Fiscal* (incluye citas a Zumaya et al., 2021; Luna-Pla y Nicolás-Carlock, 2020–2023; Medina-Hernández et al., 2025; Mittal et al., 2018; Gao et al., 2021; Barwahwala et al., 2024; Lopez-Gazpio et al., 2025).
4. **Proyecto CIMAT–UDEC (septiembre de 2026).** *Dataset piloto consolidado de diagnósticos de madurez de compliance ISO 37301* (Dataset.csv / 2026-09-18_dataset-consolidado-pymes-h1_v1.xlsx).
5. **CIMAT (2025).** *Manual de Acceso a Recursos de Supercómputo del CIMAT: Guanajuato / Puerto Interior / Mérida* (Manual de Acceso a Recursos-1.pdf).
6. **CONACYT – CIMAT (2019).** *Reglamento del Laboratorio de Supercómputo del Bajío, Versión 1 (08/01/19)* (Reglamento lab de supercomputo.pdf).
7. **Universidad de Celaya (2026).** *Lámina resumen de la sesión de arranque (CIMAT.png)* y *Organización de Equipos (Equipos.md)*.